



Escola Politécnica de Pernambuco
Especialização em Ciência de Dados e Analytics

Estatística Computacional

Aula 3.1 – Modelos de Regressão – PARTE I

Prof. Dr. Rodrigo Lins Rodrigues

rodrigo.linsrodrigues@ufrpe.br

Recapitulando o que vimos

- Estatística Descritiva ou Exploratória:
 - ✓ Medidas de tendência central;
 - ✓ Medidas de dispersão;
 - ✓ Representação gráfica;
 - ✓ Representação tabular;
 - ✓ Correlação;
- Testes de hipóteses;
 - ✓ Para um valor de referência;
 - ✓ Para populações independentes;
 - ✓ Para dados pareados;
- ANOVA;



Conteúdo programático

- ✓ Entendimento sobre Regressão Linear Simples e Múltipla;
- ✓ Diferenças entre Correlação x Regressão;
- ✓ Conhecer os pressupostos da regressão;
- ✓ Estimar parâmetros do modelo;
- ✓ Compreender o coeficiente de determinação;
- ✓ Modelo de Regressão Logística;
- ✓ Prática computacional de Regressão.



... Sobre as avaliações

- **Avaliações Teóricas:**

- ✓ Exercícios em sala de aula – 40%
- ✓ Participação em sala – 10%

- **Avaliações Práticas**


- ✓ Realização de projetos práticos – 25%
- ✓ Apresentação dos resultados – 25%



Introdução a Regressão


Introdução a Regressão

- A finalidade de uma análise de regressão é **estimar valores de uma variável**, com base em **valores conhecidos de outra variável**:
 - ✓ Um economista pode tentar explicar as variações na procura de automóveis usados em termos de desemprego;
 - ✓ Um agricultor pode suspeitar que a quantidade de fertilizante por ele usada tenha influenciado a safra.



Introdução a Regressão

- É uma das técnicas **mais utilizadas** na academia e no mercado;
- É importante enfatizar que todo modelo de regressão deve ser **definido com base na teoria e na experiência** do pesquisador;
- **Evitando relações absurdas** dentro de um contexto de pesquisa específico.



Introdução a Regressão

Qual a diferença entre
Correlação e **Regressão**?



Introdução a Regressão

- Correlação: medida ***descritiva*** que mede força da relação entre duas variáveis quantitativas;
- Regressão: A finalidade é ***estimar valores*** de uma variável, com base em valores ***conhecidos da outra a partir de um modelo***;

Introdução a Regressão

- Existem diversos tipos de modelos de regressão;
- Conhecidos como G.L.M (*Modelos Generalizados*);
- Os principais são:

Modelo de Regressão	Variável Dependente	Distribuição	Função (variável dependente)
Regressão Linear	Quantitativa	Normal	\hat{Y}
Logística Binária	Binária	Bernoulli	$\ln\left(\frac{p}{1-p}\right)$
Logística Multinomial	Qualitativa ($y > 2$)	Binomial	$\ln\left(\frac{P_m}{1-P_m}\right)$
Regressão de Poisson	Quantitativa (contagem)	Poisson	$\ln(\lambda)$

Introdução a Regressão

- Neste curso iremos conhecer dois tipos:

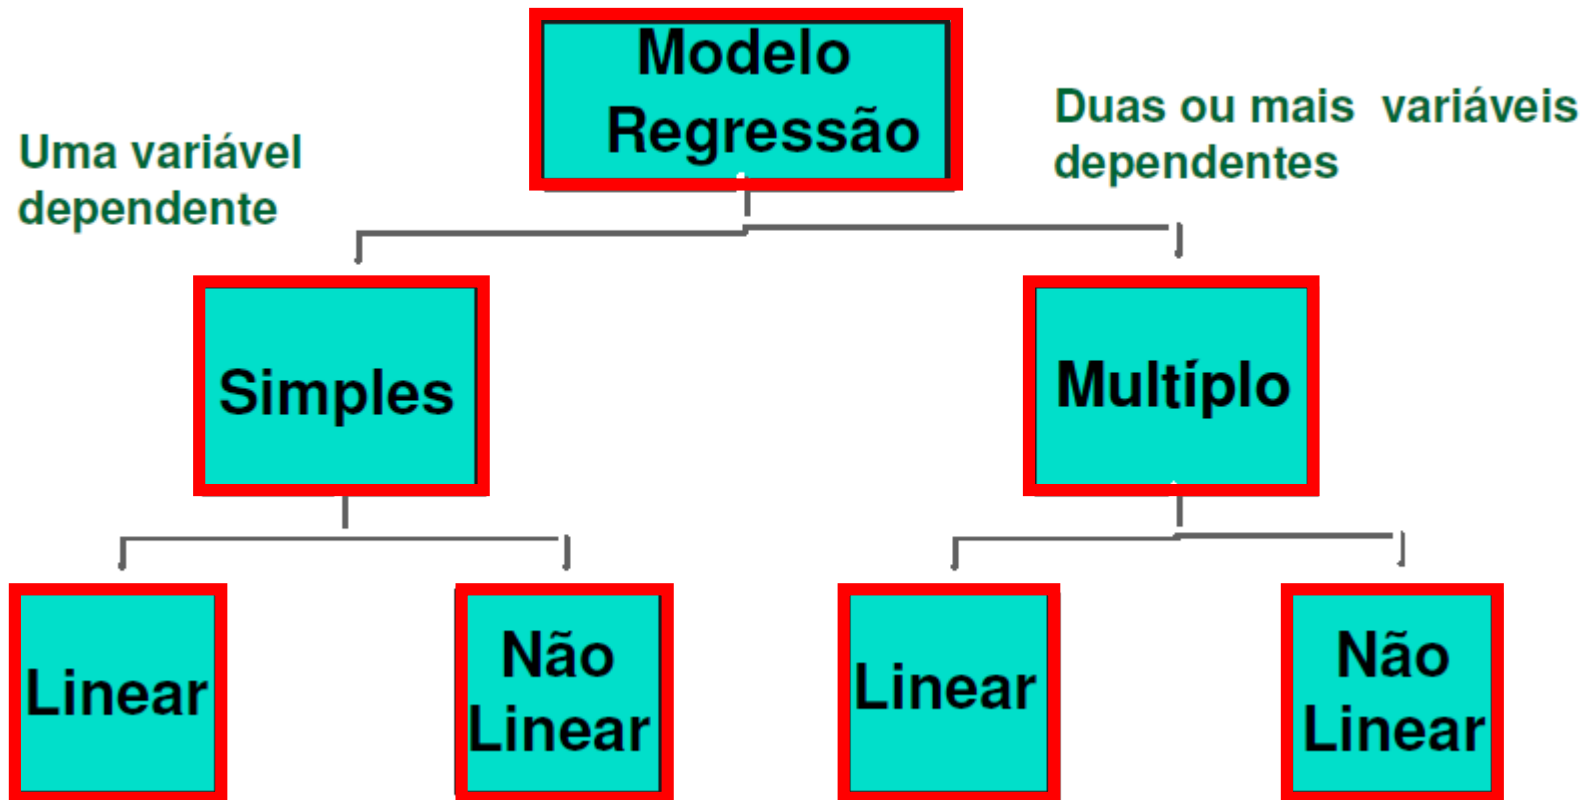
Modelo de Regressão	Variável Dependente	Distribuição	Função (variável dependente)
Regressão Linear	Quantitativa	Normal	\hat{Y}
Logística Binária	Binária	Bernoulli	$\ln\left(\frac{p}{1-p}\right)$
Logística Multinomial	Qualitativa ($y > 2$)	Binomial	$\ln\left(\frac{P_m}{1-P_m}\right)$
Poisson	Quantitativa (contagem)	Poisson	$\ln(\lambda)$

Introdução a Regressão

- Neste curso iremos conhecer dois tipos:

Modelo de Regressão	Função (variável dependente)
Regressão Linear	$\hat{Y} = \alpha + \beta_1 \cdot X_{1i} + \beta_2 \cdot X_{2i} + \cdots + \beta_k \cdot X_{ki}$
Logística Binária	$\ln\left(\frac{p}{1-p}\right) = \hat{Y} = \alpha + \beta_1 \cdot X_{1i} + \beta_2 \cdot X_{2i} + \cdots + \beta_k \cdot X_{ki}$


Introdução a Regressão



Introdução a Regressão

- **Regressão Linear Simples:**

- ✓ É um tipo de regressão linear com apenas **uma variável independente** e apenas **uma variável dependente**;
- ✓ Boa parte do nosso raciocínio processa funções e modelos linear simples:
 - Se a inflação do mês que vem for maior, então compraremos menos;
 - Se eu fizer mais horas de esporte por semana, poderei reduzir meus níveis de colesterol;
 - Se eu estudar mais, poderei ter mais oportunidades de aumentar minha renda;



Introdução a Regressão

- **Regressão Linear Simples:**

- ✓ Para o exemplo “aumento de estudo”, outras variáveis afetam a renda;
- ✓ A regressão linear simples, simplifica a relação:

$$renda = \hat{Y} = \alpha + \beta \cdot edu + \mu$$

- ✓ Normalmente busca-se identificar os sinais e valor de β ;
- ✓ Para analisar se a influência é positiva ou negativa.

Introdução a Regressão

- **Regressão Linear Múltipla**
 - ✓ Apresenta a mesma lógica da Regressão Linear Simples;
 - ✓ Com a inclusão de mais de uma variável explicativa (X_i) no modelo;
 - ✓ A utilização de muitas variáveis explicativas dependerá da experiência e do bom senso do pesquisador;
 - ✓ É importante que seja analisado criteriosamente o poder de cada variável inserida no modelo;

Introdução a Regressão

- **Exemplo Regressão Linear Múltipla**

- ✓ O gestor de uma fábrica de chocolates está interessado em avaliar o impacto da produção de embalagens para chocolates (*emb*) e da elevação da produção (*ton*) nos custos indiretos (*ci*) da empresa;
- ✓ Neste caso existem duas variáveis explicativas;
- ✓ Portanto o modelo de regressão múltipla é definido por:

$$ci = \alpha + \beta_1 \cdot emb + \beta_2 \cdot ton + \mu$$

Modelo de Regressão Linear

1. Determinar como duas variáveis se relacionam;
2. Estimar a **função que determina a relação** entre as variáveis;
3. Usar a equação ajustada para **prever valores da variável dependente**:

Modelo de Regressão Linear Simples

$$Y_i = \alpha + \beta X_i + \mu_i$$

Modelo de Regressão Linear


Pressupostos do modelo de Regressão Linear

- A relação entre X e Y é Linear;
- Os valores de X são fixos, isto é, X não é uma variável aleatória;
- A média dos erros é nula, isto é:
$$E(\mu_i) = 0 \quad i = 1, 2, \dots, n$$
- O erro em uma observação é **não correlacionado** com o erro em qualquer outra observação;

$$Var(\mu_i) = E(\mu_i) - [E(\mu_i)]^2 = E(\mu_i^2) = \sigma^2$$

- Os erros têm **distribuição normal**

Modelo de Regressão Linear



$$E(Y) = \alpha + \beta x_i$$

$$Y_i = \alpha + \beta X_i + \mu_i$$

Diagram illustrating the components of the linear regression model equation $Y_i = \alpha + \beta X_i + \mu_i$:

- Y_i is labeled "Variável Dependente" (Dependent Variable).
- X_i is labeled "Variável Independente" (Independent Variable).
- α is labeled "Intercepto populacional" (Population Intercept).
- β is labeled "Inclinação populacional" (Population Slope).
- μ_i is labeled "Erro Aleatório" (Random Error).

Modelo de Regressão Linear

- Estimadores α e β

$$\beta = \frac{\sum_{i=1}^n (X_i - \bar{X}) \cdot (Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

$$\alpha = \bar{Y} - \beta \cdot \bar{X}$$

Modelo de Regressão Linear

- **Exemplo 1:**

- ✓ Deseja-se saber, para uma turma de 10 alunos, qual a influência da distância percorrida para se chegar à escola em relação ao tempo de percurso;
- ✓ Elaborou-se um questionário e aplicou para os 10 alunos da turma;
- ✓ Com as variáveis: (y) *Tempo para se chegar a escola* e (x) *Distância percorrida até a escola*.

Modelo de Regressão Linear

- **Exemplo 1:**

✓ A tabela abaixo mostra os resultados declarados pelos alunos:

Estudante	Tempo para chegar à escola (min)	Distância percorrida até a escola (km)
Gabriela	15	8
Dalila	20	6
Gustavo	20	15
Letícia	40	20
Luiz Otávio	50	25
Leonor	25	11
Ana	10	5
Antônio	55	32
Júlia	35	28
Mariana	30	20

Modelo de Regressão Linear

- **Exemplo:**

- ✓ Na verdade estamos interessados em modelar a equação que regula o fenômeno “tempo de percurso até a escola”;
- ✓ Sabemos que outras vereáveis influenciam o tempo de percurso, mas iremos delimitar em um problema linear simples;
- ✓ Queremos modelar o problema da seguinte forma:

$$tempo = f(dist)$$

Modelo de Regressão Linear

- **Exemplo:**

- ✓ Logo, o modelo de regressão simples, será:

$$tempo_i = \alpha + \beta \cdot dist_i + \mu_i$$

- É necessário encontrar os valores dos parâmetros α e β :

$$\beta = \frac{\sum_{i=1}^n (X_i - \bar{X}) \cdot (Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

$$\alpha = \bar{Y} - \beta \cdot \bar{X}$$

Modelo de Regressão Linear

- **Exemplo:**
 - ✓ Constrói-se a tabela de valores:

Estudante	Tempo (Y_i)	Distância (X_i)	$Y_i - \bar{Y}$	$X_i - \bar{X}$	$(X_i - \bar{X}) \cdot (Y_i - \bar{Y})$	$(X_i - \bar{X})^2$
Gabriela	15	8	-15	-9	135	81
Dalila	20	6	-10	-11	110	121
Gustavo	20	15	-10	-2	20	4
Letícia	40	20	10	3	30	9
Luiz Otávio	50	25	20	8	160	64
Leonor	25	11	-5	-6	30	36
Ana	10	5	-20	-12	240	144
Antônio	55	32	25	15	375	225
Júlia	35	28	5	11	55	121
Mariana	30	20	0	3	0	9
Soma	300	170			1155	814
Média	30	17				

Modelo de Regressão Linear

- **Exemplo:**

✓ Por meio da planilha construída podemos calcular os parâmetros α e β :


$$\beta = \frac{\sum_{i=1}^n (X_i - \bar{X}) \cdot (Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} \Rightarrow \beta = \frac{1155}{814} \Rightarrow \boxed{\beta = 1,4189}$$

$$\alpha = \bar{Y} - \beta \cdot \bar{X} \Rightarrow \alpha = 30 - 1,4189 \cdot 17 \Rightarrow \boxed{\alpha = 5,8784}$$

Modelo de Regressão Linear

- **Exemplo:**
 - ✓ Logo, a equação de regressão linear simples será:

$$tempo_i = 5,8784 + 1,4189 * dist_i$$



Modelo de Regressão Linear

- O **coeficiente de determinação** é uma medida da proporção da variabilidade em uma variável que é explicada pela variabilidade da outra;
- O coeficiente de determinação é definido por:

$$R^2 = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + \sum_{i=1}^n (u_i)^2}$$

- O coeficiente está entre $0 \leq R^2 \leq 1$.

Modelo de Regressão Linear

- Voltando ao exemplo 1 em que queríamos ver a relação de *(y) Tempo para se chegar a escola* e *(x) Distância percorrida até a escola...*
- Queremos agora verificar a **adequação do modelo linear** para os dados da pesquisa;
- Para isto precisamos construir a tabela par ao calculo do **coeficiente de determinação** ou **ajuste R^2** .

Modelo de Regressão Linear

- Construindo a tabela, temos...

Estudante	Tempo (Y_i)	Distância (X_i)	\hat{Y}_i	$u_i(Y_i - \hat{Y}_i)$	$(Y_i - \hat{Y}_i)^2$	$(u_i)^2$
Gabriela	15	8	17,23	-2,23	163,08	4,97
Dalila	20	6	14,39	5,61	243,61	31,45
Gustavo	20	15	27,16	-7,16	8,05	51,3
Letícia	40	20	34,26	5,74	18,12	32,98
Luiz Otávio	50	25	41,35	8,65	128,85	74,8
Leonor	25	11	21,49	3,51	72,48	12,34
Ana	10	5	12,97	-2,97	289,92	8,84
Antônio	55	32	51,28	3,72	453,00	13,81
Júlia	35	28	45,61	-10,61	243,61	112,53
Mariana	30	20	34,26	-4,26	18,12	18,12
Soma	300	170			1638,85	361,15
Média	30	17				

Modelo de Regressão Linear

- Logo, calculamos o coeficiente de determinação:

$$R^2 = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + \sum_{i=1}^n (u_i)^2} \Rightarrow R^2 = \frac{1638,85}{1638,85 - 361,15} \Rightarrow R^2 = 0,8194$$

- Podemos afirmar que, para a amostra estudada, 81,94% da variabilidade do tempo para se chegar a escola pode ser explicado pela variável distância.

Modelo de Regressão Linear

- **Teste de significância dos parâmetros:**
- Agora, uma vez que o modelo foi ajustado e todos os parâmetros estimados surgem a seguinte pergunta:
 - ✓ Existe realmente alguma relação linear entre X e Y ? Como podemos responder isso estatisticamente ?
- Para responder à pergunta , observamos que se $\beta = 0$ não existe relação linear explicando Y em função de X.

Modelo de Regressão Linear

- Assim, a estatística F é uma estatística para testar:

$$\begin{cases} H_0: \beta = 0 \\ H_1: \beta \neq 0 \end{cases}$$

$$F = \frac{QMReg}{QMRes} \sim F_{1;n-2}$$

se H_0 **verdadeiro** (Não existe relação linear)

se H_0 **falso** (existe relação linear)


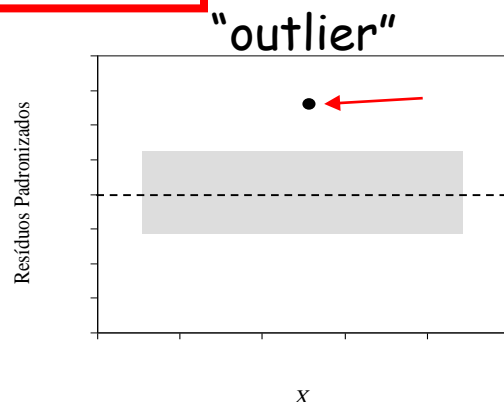
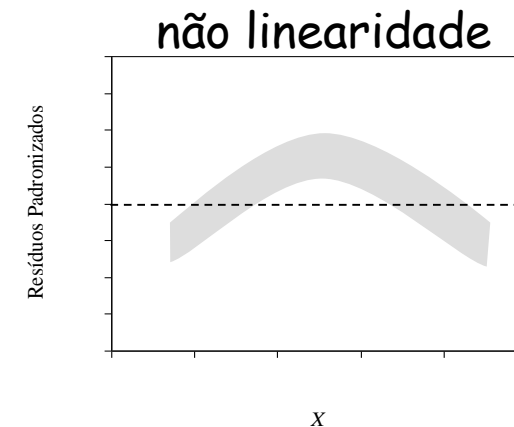

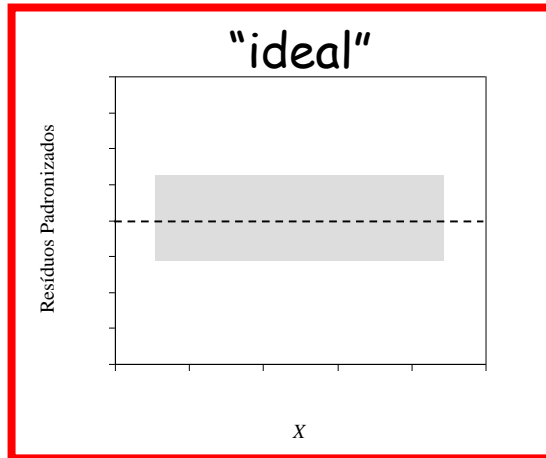
Modelo de Regressão Linear

- **Análise de Resíduos:**

- ✓ É importante, após a análise de regressão, testar se os pressupostos do modelo linear se aplicam aos dados estudados;
- ✓ Resíduos representam a diferença entre o valor observado de y e o que foi predito pelo modelo de regressão;

Modelo de Regressão Linear

- **Análise de Resíduos:**



Modelo de Regressão Linear

- **Ajuste do modelo de regressão:**
 - Pode ser verificado através de um **gráfico de dispersão** entre X e Y;
 - Existem funções que podem ser **transformadas em modelos lineares**;
 - Existem vários tipos de funções que podemos transformar, tais como:
 - ✓ Função Potência;
 - ✓ Função Exponencial;
 - ✓ Função Hiperbólica.

Agora é com vocês !

- Qual a diferença entre regressão linear simples e Múltipla?
- Para que serve o coeficiente de determinação e quais seu intervalo de variação ?



A young man with dark hair, wearing a red and white striped shirt, is holding a magnifying glass over a chalkboard. The chalkboard is filled with various mathematical diagrams, including bar charts, line graphs, and geometric shapes. The man has a focused expression, looking through the magnifying glass. A blue semi-transparent banner is overlaid on the bottom right of the image, containing the title text in yellow.

Exemplos com Regressão Linear


Exemplos com Regressão Linear

- Exemplo Regressão Linear Simples
 - ✓ Para o banco de dados sobre característica de pessoas *dados.txt* na pasta Aula 3.1 - Modelos de Regressão\Scripts - Aula 3.1;
 - ✓ Iremos construir um modelo de regressão simples com as variáveis $y = \text{Peso}$ e $x = \text{altura}$;
 - ✓ Construiremos um modelo que explique o peso de um indivíduo em função de sua altura.

Exemplos com Regressão Linear

- Exemplo Regressão Linear Simples

```
5 # Ler os dados de um arquivo (interagindo com o usuário)
6 dados <- read.table(file.choose(),header=TRUE)
7
8 # Visão descritiva (gráfica sobre as duas variáveis)
9 plot(dados$Peso, dados$Altura)
```



Exemplos com Regressão Linear

- Exemplo Regressão Linear Simples

```
11 # Construindo o modelo de regressão linear múltiplo
12 modelo <- lm(dados$Peso~dados$Altura)
13
14 # Visualizando o modelo
15 modelo
```

call:

```
lm(formula = dados$Peso ~ dados$Altura)
```

coefficients:

(Intercept)	dados\$Altura
-88.21	95.16

Exemplos com Regressão Linear

- Exemplo Regressão Linear Simples

```
17 # Mostrando o resultado do modelo
18 summary(modelo)
```

```
call:
lm(formula = dados$Peso ~ dados$Altura)

Residuals:
    Min       1Q   Median       3Q      Max
-10.1720  -1.1639   0.1989   1.0698   4.5376


Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   -88.214     3.940  -22.39  <2e-16 ***
dados$Altura   95.161     2.308   41.23  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.355 on 37 degrees of freedom
Multiple R-squared:  0.9787, Adjusted R-squared:  0.9781
F-statistic: 1700 on 1 and 37 DF, p-value: < 2.2e-16
```

Exemplos com Regressão Linear

- Exemplo Regressão Linear Simples


```
20 # Gerando os resíduos padronizados
21 padronizados <- rstandard(modelo)
22
23 # Plotando o gráfico dos resíduos
24 plot(dados$Peso, padronizados)
```



Exemplos com Regressão Linear

- Exemplo Regressão Linear Simples

```
26 # Verificando a normalidade dos resíduos pelo qqplot
27 qqnorm(padronizados)
28 qqline(padronizados)
```



Exemplos com Regressão Linear

- **Exemplo Regressão Linear Múltipla**

- ✓ Vamos utilizar o mesmo exemplo;
- ✓ Adicionaremos a variável “*Renda*”;
- ✓ Este modelo terá a variável $y = \text{Peso}$ e duas variáveis explicativas $x1 = \text{Altura}$ e $x2 = \text{Renda}$;

Exemplos com Regressão Linear

- Exemplo Regressão Linear Múltipla

```
5 # Ler os dados de um arquivo (interagindo com o usuário)
6 dados <- read.table(file.choose(),header=TRUE)
7
8 # Construindo o modelo de regressão linear múltiplo
9 modelo <- lm(dados$Peso~dados$Altura + dados$Renda)
```


Exemplos com Regressão Linear

- Exemplo Regressão Linear Múltipla

```
5 # Ler os dados de um arquivo (interagindo com o usuário)
6 dados <- read.table(file.choose(), header=TRUE)
7
8 # Construindo o modelo de regressão linear múltiplo
9 modelo <- lm(dados$Peso~dados$Altura + dados$Renda)
10
11 # Visualizando o modelo
12 modelo
```

call:

```
lm(formula = dados$Peso ~ dados$Altura + dados$Renda)
```

Coefficients:

(Intercept)	dados\$Altura	dados\$Renda
-8.821e+01	9.516e+01	7.960e-07

Exemplos com Regressão Linear

- Exemplo Regressão Linear Múltipla

```
14 # Mostrando o resultado do modelo
15 summary(modelo)
```

```
Call:
lm(formula = dados$Peso ~ dados$Altura + dados$Renda)

Residuals:
    Min       1Q   Median       3Q      Max
-10.1711  -1.1653   0.1996   1.0704   4.5380

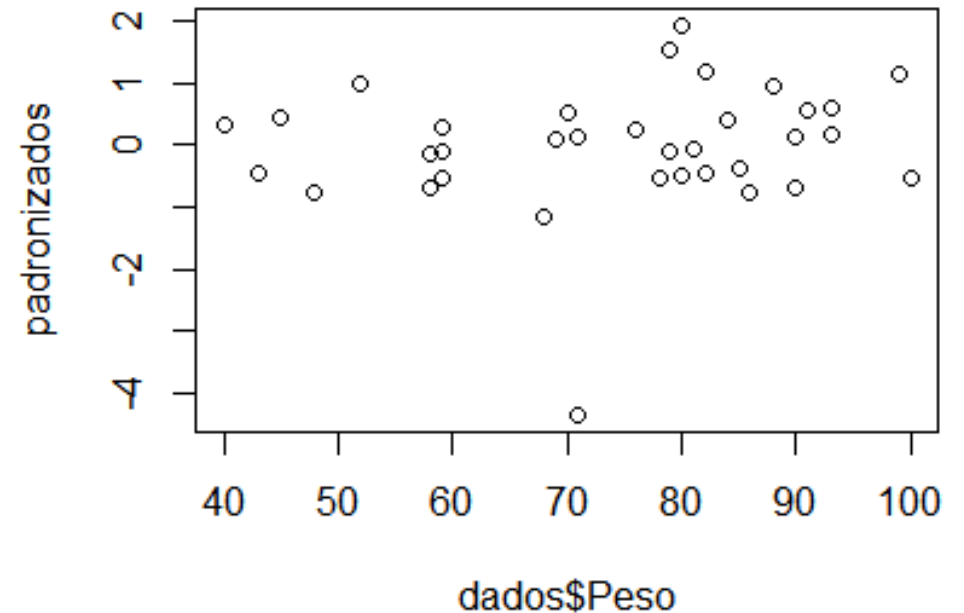
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -8.821e+01  3.994e+00 -22.086  <2e-16 ***
dados$Altura   9.516e+01  2.349e+00  40.519  <2e-16 ***
dados$Renda    7.960e-07  2.212e-04   0.004    0.997
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.388 on 36 degrees of freedom
Multiple R-squared:  0.9787,    Adjusted R-squared:  0.9775
F-statistic: 826.8 on 2 and 36 DF,  p-value: < 2.2e-16
```

Exemplos com Regressão Linear

- Exemplo Regressão Linear Múltipla


```
14 # Mostrando o resultado do modelo
15 summary(modelo)
16
17 # Gerando os resíduos padronizados
18 padronizados <- rstandard(modelo)
19
20 # Plotando o gráfico dos resíduos
21 plot(dados$Peso, padronizados)
```



Exemplos com Regressão Linear

- Exemplo Regressão Linear Múltipla

```
23 # Verificando a normalidade dos resíduos pelo qqplot
24 qqnorm(padronizados)
25 qqline(padronizados)
```



Dúvidas



- **Contatos:**

- ✓ Email: rodrigo.linsrodrigues@ufrpe.br

- ✓ Facebook: [/rodrigomuribec](https://www.facebook.com/rodrigomuribec)